### Interprétation et analyse de programmes

Didier Buchs

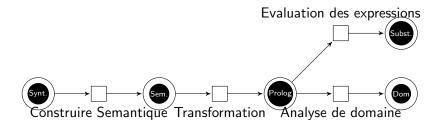
Université de Genève

23 avril 2018

# Vers un interpréteur

- Il s'agit de produire un programme prenant en entrée le langage à interprèter et produisant l'état du programme après l'exécution
- Prolog est un bon langage pour réaliser cette tâche, néanmoins un certain nombre de définitions dans la sémantique ne sont pas assez opérationelles ni suffisamment concrètes.
- L'implémentation des règles sert à l'animation et même éventuellement à l'évaluation de propriétés du langage.
- Dans la suite, Prolog sera employé mais les mêmes principes peuvent être utilisé pour d'autres langages au prix de certaines difficultés par rapport à la gestion des termes.

# Processus pour l'obtention d'un interpréteur



### Principes à appliquer :

- Etablir la structure syntaxique du langage en prolog
- Définir la notion d'état d'un programme
- Définir quelques procédures de manipulation (substitutions, listes, ...)
- Traduire en prolog les règles sémantiques sans en changer le sens
  - Filtrer la règle applicable de manière unique
  - Evaluer les préconditions
  - Etablir l'effet de la règle
  - Equations algébriques à résoudre
- Pièges : non-déterminisme, problèmes de négation.

# Syntaxe en Prolog

- Deux solutions :
  - Utiliser les grammaires DCG pré-implémentée en Prolog
  - Utiliser pragmatiquement, termes, opérateurs et foncteurs pour encoder les unités syntaxiques
- Grammaires DCG (Direct Clause Grammar) présenté dans le cours de compilation.  $g -> a, b, \ldots, d$ .
- Opérateurs en Prolog

```
:-op(50,xfx,-->).
:-op(500,yfx,+).
:-op(900,fy,not).
:-op(700,xfx,=).
```

# Syntaxe du Langage minimal et Prolog

- Opérateur  $_{-}+_{-}: 1+y*3-4*7+x$
- Opérateur  $\_<\_: sq(y) < x$
- Expressions :
  - Variable atome prolog = atom(x)
  - Termes, foncteurs pour appel de fonction
- Instructions :
  - $\bullet$  \_ := \_ : y := y + 1
  - *if*\_then\_else(\_, \_, \_)
  - while(\_, \_)
- Programmes :
  - Séquence \_; \_
  - Fonctions: func(\_, \_):
     func(sqrt(x), y := 1; while(sq(y) < x, y := y + 1); return y)</li>

### Exemple

- ?- eval([func(sqrt(x),y:=1;while(y\*y<x,y:=y+1); return x:=sqrt(65536),S).
- Contexte des fonctions :

```
func(sqrt(x),y:=1;while(y*y<x,y:=y+1); return y)
pour simplifier dans l'implémentation qui suit, la dernière
instruction est un 'return'!!
func(sqrt(x),y:=1;while(y*y<x,y:=y+1), y)</pre>
```

• Le corps du programme :

```
x:=sqrt(65536)
```

- S, substitution = ensemble de couples
- Résultat : S = [(x, 256)];

# Comment construire l'interpréteur : fonctions d'évaluations majeures

- bigstep\_e : calcule l'expression entière (e) pour une substitution donnée (S) et un ensemble de fonctions (PROG) : env(PROG, S), e-> N
- bigstep\_c : calcule les conditions (e) pour une substitution donnée (S) et un ensemble de fonctions (PROG) : env(PROG, S), e-> N
- bigstep\_i : calcule (S') l'effet d'une instruction sur une substitution (S) connaissant un ensemble de fonctions (PROG): PROG, i, S-> S
- $bigstep_b$ : calcule (S') l'effet d'une séquence d'instructions (p): PROG, p, S-> S
- $eval(ENV, P, S) : -bigstep\_b(ENV, P, [], S)$ .

### Substitutions

Trouver la valeur définie pour une variable

ajouter une valeur a une variable dans la substitution (propriétés telles que unicité et non-ordre prise en compte)

### Expressions et relations

Se basent sur l'implémentation de prolog des entiers :

```
bigstep_c(ENV,E < EE):-
    bigstep_e(ENV,E,N),bigstep_e(ENV,EE,NN),N < NN.
bigstep_c(ENV,E > EE):-
    bigstep_e(ENV,E,N),bigstep_e(ENV,EE,NN),N > NN.
bigstep_c(ENV,E = EE):-
    bigstep_e(ENV,E,N),bigstep_e(ENV,EE,NN),N = NN.
bigstep_c(ENV,E \== EE):-
    bigstep_e(ENV,E,N),bigstep_e(ENV,EE,NN),N \== NN.
```

### Expressions : opérations

```
bigstep_e(ENV,E + EE,NS):-
    bigstep_e(ENV,E,N),bigstep_e(ENV,EE,NN),NS is N + NN.
bigstep_e(ENV,E * EE,NS):-
    bigstep_e(ENV,E,N),bigstep_e(ENV,EE,NN),NS is N * NN.
bigstep_e(ENV,E / EE,NS):-
    bigstep_e(ENV,E,N),bigstep_e(ENV,EE,NN),NS is N / NN.
bigstep_e(ENV,E - EE,NS):-
    bigstep_e(ENV,E,N),bigstep_e(ENV,EE,NN),NS is N - NN.
```

bigstep\_e(ENV,N,N):-integer(N).

### **Traduction**

### Definition (Sémantique d'évaluation )

$$e\in \textit{ExpVar}=T_{\{+,-,*,/\}}(\mathbb{N}\cup V)$$
 et  $n\in\mathbb{N}$  ,  $s\in\textit{Subs}+_{\mathbb{N}},*_{\mathbb{N}},-_{\mathbb{N}},/_{\mathbb{N}}$  sont les fonctions sur  $\mathbb{N}$ 

R Constante : 
$$\overline{S \vdash n \Longrightarrow n}$$
  
 $R-: \frac{S \vdash e \Longrightarrow n, S \vdash e' \Longrightarrow n'}{S \vdash e - e' \Longrightarrow n - \mathbb{N} n'}$ 

#### Devient:

bigstep\_e(ENV,N,N):-integer(N).

12/38

### Expressions : variables

N = -1

```
\label{eq:bigstep_e(env(PROG,S),V,N):-atom(V),subsextract(S,V,N).} Les variables sont des atomes! \label{eq:contexte} \begin{cases} \begin
```

### Expressions: appel de fonctions

```
Les functions sans paramètres ne sont pas autorisées (sinon
confusion avec les variables!!) Appel de fonctions par 'functors'
bigstep_e(env(PROG,S),FCTCALL,N):-
          FCTCALL = .. [NAME | PARAM], length (PARAM, M), M>O,
          findfunction (PROG. NAME.
                          func (NAMEPARAMFORMAL, FBODY, ERETURN)
          NAMEPARAMFORMAL = .. [NAME | PARAMFORMAL].
          bigstep_le(env(PROG,S),PARAM,LN),
          bindparam(LN, PARAMFORMAL, SS),
          bigstep_p(PROG,FBODY,SS,SSS),
          bigstep_e(env(PROG,SSS),ERETURN,N).
```

# Expressions : appel de fonctions Variante 1

```
Variables globales qui sont supposées sans collision de nom,
attention au paramètre de retour de substitution (effet de bord)
bigstep_e(env(PROG,S),FCTCALL,N,S5):-
          FCTCALL = .. [NAME | PARAM], length (PARAM, M), M>O,
          findfunction (PROG. NAME.
                         func (NAMEPARAMFORMAL, FBODY, ERETURN)
          NAMEPARAMFORMAL = .. [NAME | PARAMFORMAL].
          bigstep_le(env(PROG,S),PARAM,LN),
          bindparam(LN, PARAMFORMAL, SS),
          merge(S,SS,S4),
          bigstep_p(PROG,FBODY,S4,SSS),
          bigstep_e(env(PROG,SSS),ERETURN,N),
          extract(SSS,S5).
```

### Expressions : appel de fonctions

### Instructions: if then else

### Instructions: while

### Instructions: affectation

rappel de la règle originale :

Definition (Sémantique d'évaluation : Règle affectation )

 $e \in \textit{ExprVar}_V \text{ et } v \in V \text{ , } S, S', S'' \in \textit{Subs}$ 

Raffectation : 
$$\frac{S \vdash e \Longrightarrow n}{S \vdash v := e \Longrightarrow_{I} S/[v = n]}$$

### **Blocs**

La sémantique d'un programme comme une liste d'instructions

```
bigstep_p(PROG,(I;P),S,SSS):-!,
    bigstep_i(PROG,I,S,SS),
    bigstep_p(PROG,P,SS,SSS).
```

cut pour sélectionner seulement une instruction.

```
\label{eq:bigstep_p(PROG,I,S,SS):-bigstep_i(PROG,I,S,SS)} bigstep\_i(PROG,I,S,SS) \, .
```

### Exercice

sachant qu'un langage de manipulation binaire à la syntaxe abstraite suivante :

$$exp = exp + exp$$
 union bit par bit  $exp = bin$  nombre binaires  $exp => exp$  shift right  $exp =< exp$  shift left  $bin = digitbin|digit$  ex : 1010101  $digit = 0|1$ 

En utilisant les règles produites pour ce langage, donner un programme Prolog 'interprétant' ce langage.

# Exercice : (syntaxe)

# Exercice : (sémantique)

### Analyse de programmes

- La sémantique de notre langage impératif peut être interprétée pour analyser un programme et en étudier le comportement
- Types d'analyse possibles :
  - Trouver les chemins d'execution possibles
  - Détecter des anomalies telles que variables non initialisées, code mort, . . . .
- Comment procéder?
  - Utiliser l'interprète Prolog généré à partir de la sémantique :
    - Exécution directe
    - Exécution symbolique
  - Analyse statique
- Execution symbolique en Prolog
  - Posséder une axiomatisation des types de données (Peano pour les entiers)
  - Avoir un mécanisme d'évaluation plus 'intelligent' que la résolution SLD



# Evaluation des expressions

### **Definition**

$$e \in \textit{ExprVar}_V \text{ et } v \in V \text{ , } \textit{Var}(e) = \{v\}, \ \textit{S} \in \textit{Subs}$$

$$Dom_e(v) = \{ \langle k, n \rangle \in Num \times Num | S/[v = n] \vdash e \Longrightarrow k \}$$

Exemple : 
$$e = sqr(v)$$
  
 $Dom_e(v) = \{ <1, 1>, <1, 2>, ..., <2, 4>, ..., \}$   
Comment faire mieux?

### Evaluation des expressions

Avec l'usage de la résolution les solutions seront 'généralisées' par l'usage de variables. (identique a la lazy evaluation)

#### Definition

$$e \in \textit{ExprVar}_V \text{ et } v \in V \text{ , } \textit{Var}(e) = \{v\}, \ \textit{S} \in \textit{Subs}$$

$$\textit{SDom}_e(v) = \{ < k, e' > \in \textit{Num} \times \textit{ExprVar}_V | S/[v = e'] \vdash e \Longrightarrow k \}$$

Exemple : 
$$e = pair(v)$$

$$Dom_e(v) = \{ \langle false, 1 \rangle, \langle true, 2 \rangle, \langle true, succ(succ(0)) \rangle \}$$
  
 $, ..., \langle true, succ(succ(0)) * x \rangle, ..., \}$ 

Ce qui serait en intension :

$$Dom_{pair(x)}(v) = \{ < false, 2 * x + 1 >, < true, 2 * x > | x \in Num \}$$

# Marquage des choix

Il s'agit de 'monitorer' les choix des règles pour pouvoir décider de critères tels que la couverture ...

- Couverture des branches
- Couverture des conditions ...

Pour cela il faut complètement axiomatiser la sémantique et améliorer les preuves :

- ullet Pas de structures non connues  $(apply_{\mathbb{N}}(+))$
- Attention à la résolution SLD, en changer pour atteindre la complétude.

# Pourquoi changer la représentation des types de données

- Solution utilisant les entiers de Prolog
  - N is M1 + M2
  - Si M1 et M2 sont définis alors N est défini
  - Si N défini impossible de trouver M1 et M2 car 'is' est une fonction stricte.
- Solution correcte, rendre inversible les opérations
  - Représentation de tous entiers par les générateurs :
  - 0 et s (successeur)

Exemple: le nombre 3 est : s s s 0

### Analyse des chemins (if then else)

Exemple (X est une variable prolog definissant un domaine, x est une variable du langage) :

```
?- bigstep_b([],x:=s(X);if_then_else(x<s(s(s(0))),
                           x := x + s(0), x := x - s(0), [], R).
X = 0
R = [(x, s(s(0)))];
X = s(0)
R = [(x, s(s(s(0))))];
X = s(s(0))
R = [(x, s(s(0)))]:
X = s(s(s(G320)))
R = [(x, s(s(g(320))))];
Nο
```

# Axiomatisation des naturels (Peano)

### Générateurs

```
0 : -> nat;
S _ : nat -> nat
```

Typage par adjonction de l'arité à chaques termes

### Axiomes

$$0 + N = N$$
  
 $S(N) + N' = s(N+N')$ 

### Opérations en Prolog

Le typage est attaché à chaques termes.

# Opérations en Prolog (2)

```
peanodiv(N,NN,s(NS):(nat->nat)):-
     peanoGT(N,NN,t),peanosub(N,NN,NNN),peanodiv(NNN,NN,NS)
peanodiv(N,NN,0:(nat)):-peanoLT(N,NN,t).
peanodiv(N,NN,s(0:(nat))):-peanoEQ(N,NN,t).
peanosub(0:(nat),0:(nat),0:(nat)).
peanosub(s(N):(nat->nat),0:(nat),s(N):(nat->nat)).
peanosub(s(N):(nat->nat),s(NN):(nat->nat),NNN):-peanosub(N
```

### relations

```
peanoLT(0:(nat),s(NN):(nat->nat),t:bool).
peanoLT(0:(nat),0:(nat),f:bool).
peanoLT(s(NN):(nat->nat),0:(nat),f:bool).
peanoLT(s(NN):(nat->nat),s(N):(nat->nat),R):-peanoLT(NN,N,R)
peanoGT(N,NN,R):-peanoLT(NN,N,R).
peanoEQ(0:(nat),s(NN):(nat->nat),f:bool).
peanoEQ(0:(nat),0:(nat),t:bool).
peanoEQ(s(NN):(nat->nat),0:(nat),f:bool).
peanoEQ(s(NN):(nat->nat),s(N):(nat->nat),R):-peanoLT(NN,N,I)
peanoNEQ(N,NN,f:bool):-peanoEQ(N,NN,t:bool).
peanoNEQ(N,NN,t:bool):-peanoEQ(N,NN,f:bool).
                                                         33/38
```

### Typage, synthèse des valeurs

```
isnat(N,N):-var(N),!.
isnat(0,0:nat).
isnat(s(N), s(NN):(nat->nat)):-isnat(N,NN).
isnat(NN):-isnat(N,NN).
```

Ce prédicat produit les valeurs typées depuis des valeurs non typées connues pour un type connu.

Il peut servir de générateur de valeurs.

# Variables libres (couverture des branches)

```
?- eval(x:=s(Y);b:=B;if_then_else(b,z:=s(0)+x,z:=s(0)-x)).
x:nat = s(_G157)
b:bool = t
z:nat = s(s(G157))
Y = _G157
B = G163 :
x:nat = s(0)
b:bool = f
z:nat = 0
Y = 0:nat
B = _{G}163;
                                                           35/38
```

# Couverture minimale? (strategie et axiomatisation)

Réécriture équivalente des expressions implique un changement de comportement !!!

```
?- eval(x:=s(Y);b:=B;if_then_else(b,z:=x+s(0),z:=x-s(0))).
x:nat=s(0)
b:bool= t
z:nat=s(s(0))
Y = 0:nat
B = _{G}163;
x:nat = s(s(0))
b:bool = t
z:nat = s(s(s(0)))
x:nat = s(s(s(0)))
b:bool = t
```

### Exploration de domaines

```
?-loadfun([sqrt,sq],C),bigstep_p(C,x:=sqrt(s(s(s(0)))),[],R),
     subsprint(R).
x:nat' = 's(s(0))
?- loadfun([sqrt,sq],C),bigstep_p(C,x:=sqrt(s(s(s(X)))),[],R),
     subsprint(R).
x:nat' = 's(s(0))
X = 0:nat
x:nat' = 's(s(0))
X = s(0:nat): (nat->nat)
x:nat' = 's(s(s(0)))
X = s(s(0:nat): (nat->nat)): (nat->nat)
x:nat' = 's(s(s(0)))
X = s(s(s(0:nat): (nat->nat)): (nat->nat)): (nat->nat)
                                                              37/38
                                                             200
```

### Intérêts de l'exploration de domaines

- Vérification par test
  - Création de données de test (domaines d'entrées et hypothèses de réduction)
  - évaluation de la couverture avec instrumentation (marquage des choix)
- Analyse de programmes
  - détection de comportements aberrants (ajout des exceptions dans la sémantique, par complémentation des comportements corrects)
  - détection de violation d'invariants
  - accès interdits à la mémoire (sémantique des pointeurs et de la mémoire)

En règle générale, usage de méthodes d'aproximations avec faux positifs (preuves) (ou négatifs! tests)